Curso Básico de

Manipulación y Transformación de Datos con Pandas y NumPy



Requisitos previos

- Fundamentos de matemáticas
- Python
- Jupyter Notebooks







¿Por qué NumPy y Pandas?

¿Para qué sirven?



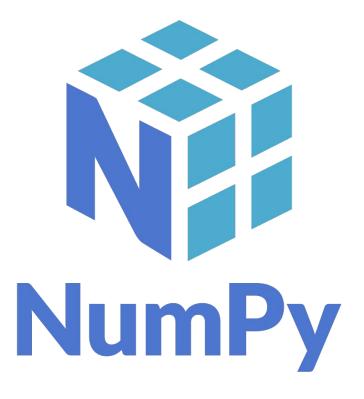


- Cálculo numérico
- Manejo de arrays

 Manipulación y análisis de datos

NumPy

- Creada en el 2005.
- 100% open source.
- Se encuentra en GitHub.
- Travis Oliphant.



¿Por qué NumPy?

- Velocidad
- Tamaño
- Tipos de datos



¡Muy poderosa!

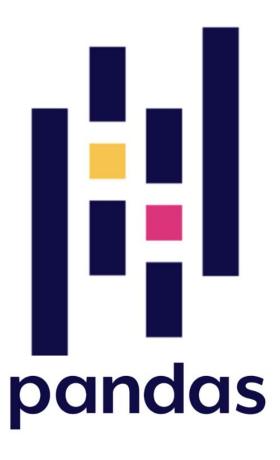
Creando nuestra red neuronal usando numpy y matemáticas





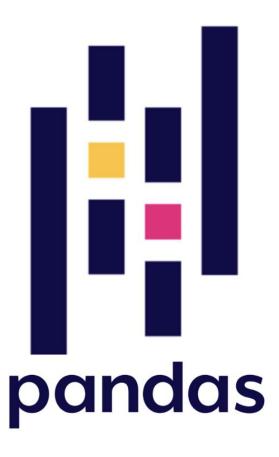
Pandas

- Creada en el 2008.
- 100% open source.
- Se encuentra en GitHub.
- Wes McKinney.
- Construida sobre NumPy.



¿Por qué Pandas?

- Velocidad
- Poco código
- Múltiples formatos de archivos
- Alineación inteligente



¡Muy poderosa!



##Importando librerías

import numpy as np import pandas as pd

Los proyectos más grandes inician así



NumPy Array

Array

- La estructura central de NumPy.
- Representa datos de una manera estructurada.
- Indexado.
- Acceso a uno o muchos elementos.

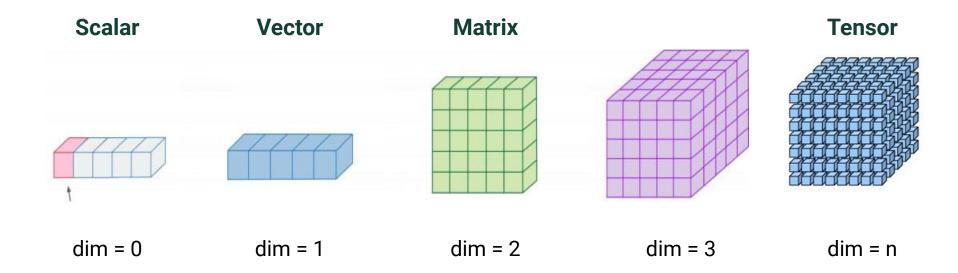


Array

Tipos de datos

Dimensiones

Dimensiones de los datos



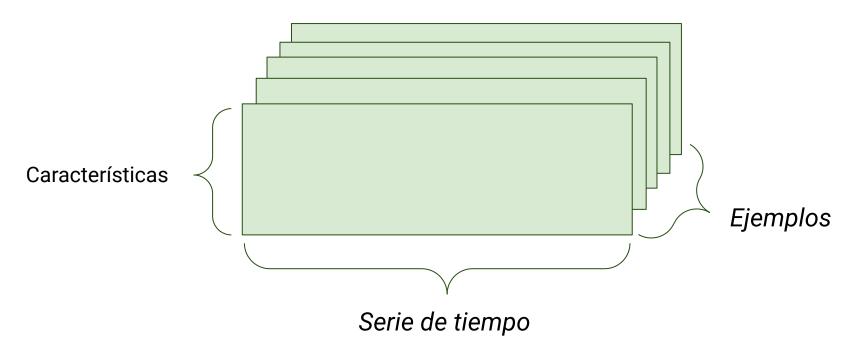
Matrix - 2D

(Ejemplos, características)

1	Α	В	С	D	Е	F
1	Order ID	Product	Category	Amount	Date	Country
2	1	Carrots	Vegetables	\$4,270	1/6/2012	United States
3	2	Broccoli	Vegetables	\$8,239	1/7/2012	United Kingdom
4	3	Banana	Fruit	\$617	1/8/2012	United States
5	4	Banana	Fruit	\$8,384	1/10/2012	Canada
6	5	Beans	Vegetables	\$2,626	1/10/2012	Germany
7	6	Orange	Fruit	\$3,610	1/11/2012	United States
8	7	Broccoli	Vegetables	\$9,062	1/11/2012	Australia
9	8	Banana	Fruit	\$6,906	1/16/2012	New Zealand
10	9	Apple	Fruit	\$2,417	1/16/2012	France
11	10	Apple	Fruit	\$7,431	1/16/2012	Canada
12	11	Banana	Fruit	\$8,250	1/16/2012	Germany
13	12	Broccoli	Vegetables	\$7,012	1/18/2012	United States
14	13	Carrots	Vegetables	\$1,903	1/20/2012	Germany

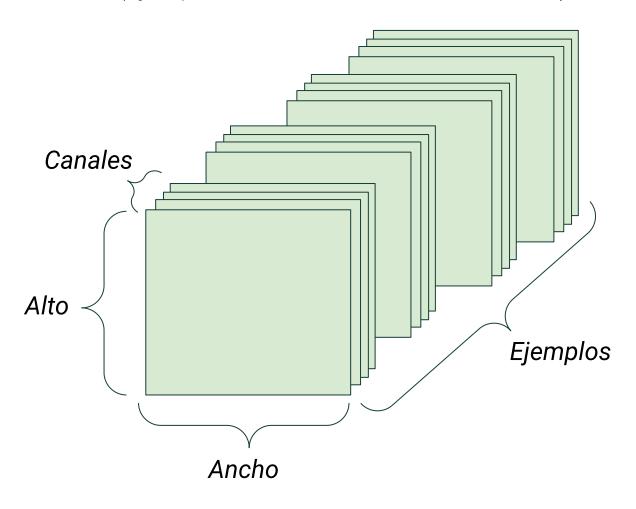
Tensor - 3D

(Ejemplos, Serie de tiempo, Características)



Tensor - 4D - Images

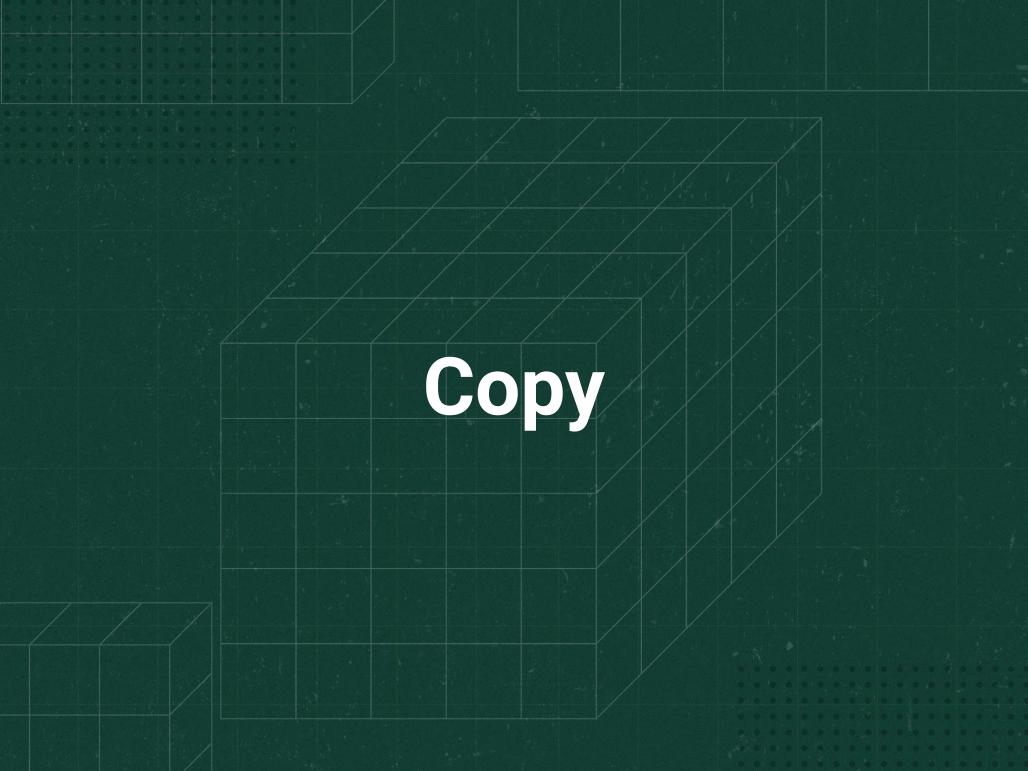
(Ejemplos, Ancho, Alto, Canales de color)



Creando arrays

Shape y Reshape

Funciones principales de NumPy



Condiciones

Operaciones

Series y DataFrames

Pandas Series

- Arreglo unidimensional indexado.
- Búsqueda por índice.
- Slicing.

Índice	Datos
1	Ά΄
2	'B'
3	'C'
4	'D'
5	'E'

Pandas Series

- Operaciones aritméticas.
- Distintos tipos de datos.

Índice	Datos
1	Ά'
2	'B'
3	'C'
4	'D'
5	'E'

Pandas DataFrame

- Estructura principal.
- Arreglo de dos dimensiones.
- Búsqueda por índice (columnas o filas).

	Key1	Key2	Key3
0	1	Hank	1.2
1	2	Steve	3.1
2	3	Lisa	3.1

Pandas DataFrame

- Slicing
- Operaciones aritméticas
- Distintos tipos de datos
- Tamaño variable

	Key1	Key2	Key3
0	1	Hank	1.2
1	2	Steve	3.1
2	3	Lisa	3.1

Leer archivos con Pandas



Agregar o eliminar datos con Pandas

Manejo de datos nulos

Filtrado por condiciones

Funciones principales de Pandas

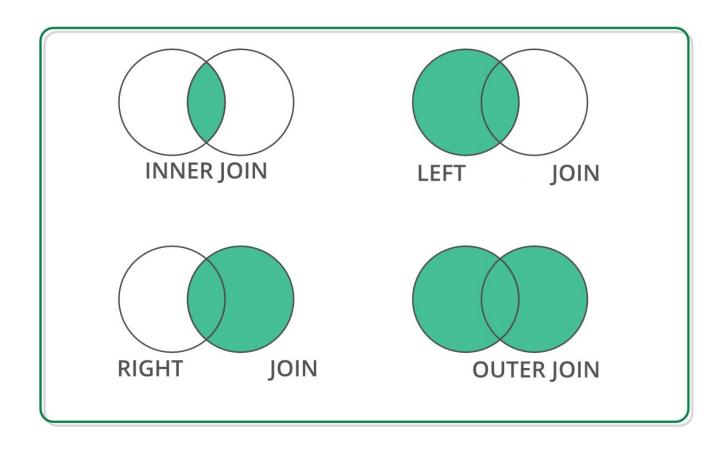


Groupby

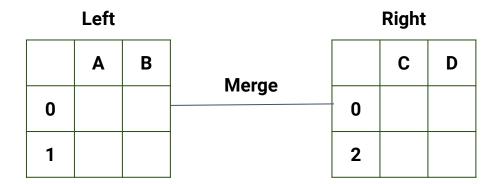
Libro	Género	Precio	Groupby				
Libro 1	Ciencia ficción	10	Genero →	Género	Sum	Count	Mean
Libro 2	Fantasía	10		Ciencia ficción	30	3	10
Libro 3	Fantasía	10					
Libro 4	Educación	10		Fantasía	20	2	10
Libro 5	Ciencia ficción	10		Educación	10	1	10
Libro 6	Ciencia ficción	10					

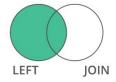
Combinando DataFrames

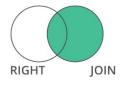
Merge - Join



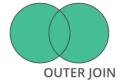
Merge - Join











	A	В	С	D
0				
1				

	A	В	С	D
0				
2				

	A	В	С	D
0				

	A	В	С	D
0				
1				
2				

Concat - Axis 0

df1

	А	В	С	D
0	A0	В0	CO	D0
1	A1	B1	C1	D1

df2

	А	В	С	D
2	A2	B2	C2	D2
3	A3	В3	C3	D3

Concat

	Α	В	С	D
0	A0	В0	C0	D0
1	A1	B1	C1	D1
2	A2	B2	C2	D2
3	A3	В3	C3	D3

Concat - Axis 1

df1

	Α	В	С	D
0	A0	В0	C0	D0
1	A1	B1	C1	D1

df2

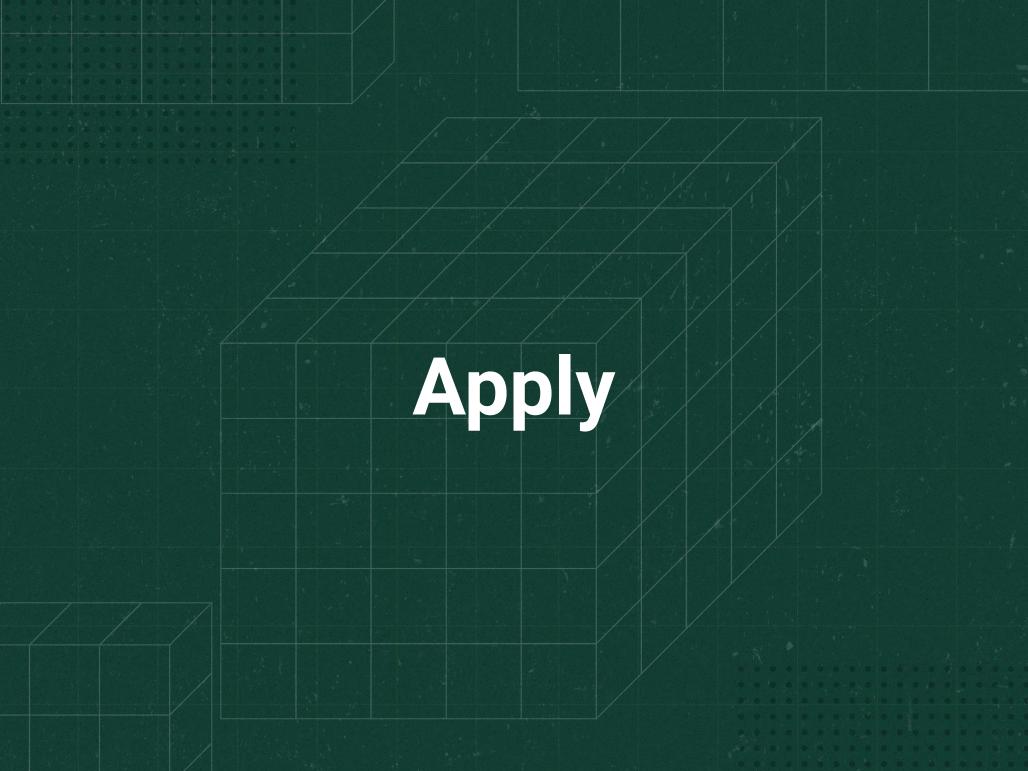
	С	D	Е	F
1	C1	D1	E1	F1
2	C2	D2	E2	F2

Concat

	Α	В	С	D	С	D	Е	F
0	A0	В0	C0	D0	NaN	NaN	NaN	NaN
1	A1	B1	C1	D1	C1	D1	E1	F1
2	NaN	NaN	NaN	NaN	C2	D2	E2	F2

Merge, Join y Concat

Pivot, Melt



Posibilidades con Pandas y NumPy

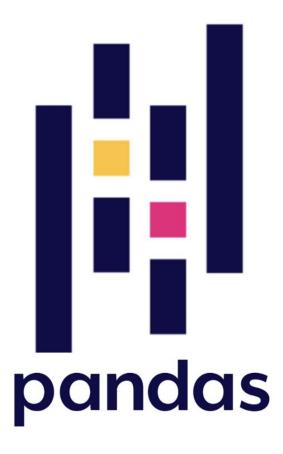
Numpy

- El Array (ventajas).
- Tipos de datos.
- Slicing.
- Index.
- Dimensiones.
- Crear arrays.

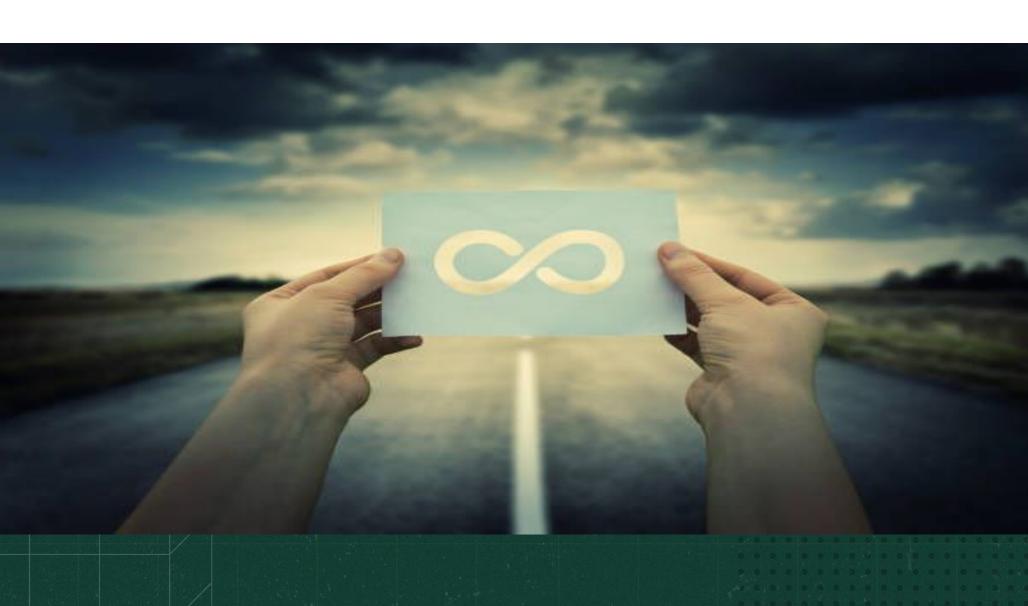
- Matemática en numpy.
- Filtrado.
- Shape Reshape.

Pandas

- Series Dataframe
- Files
- iloc loc
- Manejo de nulos (NaN)
- Funciones principales
- Merge, Concat, Join
- Apply



Posibilidades infinitas



Carlos Andrés Alarcón @Alarcon7a